

**Análisis Comparativo entre Polars y Pandas:
Predicción de Upvotes en Kaggle Success Factors**

Kristhel Porras
LEAD University

Curso: Parallel and Distributed Computing
Profesor: Johansell Villalobos Cubillo
Junio 2026

Tabla de Contenidos

1. Resumen Ejecutivo
2. Introducción
3. Metodología
4. Resultados
5. Análisis y Discusión
6. Conclusiones
7. Referencias

1. Resumen Ejecutivo

Este reporte presenta un análisis comparativo del rendimiento entre Polars y Pandas en el procesamiento del dataset "Kaggle Success Factors" para la predicción de upvotes. El análisis incluyó el entrenamiento de tres modelos de regresión (Regresión Lineal, Random Forest y Gradient Boosting) utilizando 75,418 registros con 40 variables. Los resultados demuestran que Polars supera a Pandas con un speedup promedio de 6.98x en operaciones complejas, siendo especialmente eficiente en operaciones de agregación (GroupBy: 11.03x). El modelo Random Forest logró el mejor desempeño con un R^2 de 0.8894 en datos de prueba y 0.9028 ± 0.0327 en validación cruzada. Las variables más predictivas fueron comments_count ($r = 0.83$), views ($r = 0.78$) y fork_count ($r = 0.61$). Se concluye que Polars es una alternativa superior a Pandas para pipelines ETL grandes (>100MB), especialmente cuando la complejidad del procesamiento requiere optimizaciones automáticas mediante lazy execution.

2. Introducción

La ciencia de datos moderna requiere procesar volúmenes crecientes de datos con eficiencia temporal y de memoria. Pandas ha sido la biblioteca estándar de facto durante años para análisis de datos en Python, pero nuevas bibliotecas como Polars prometen mejoras significativas en rendimiento y escalabilidad. Este proyecto compara ambas plataformas en un escenario realista: la predicción de engagement (upvotes) en publicaciones de Kaggle. El dataset contiene 75,418 registros después de limpieza de datos y 40 variables que incluyen métricas de engagement, características del autor y propiedades del contenido.

2.1. Objetivos

- Evaluar el rendimiento de Polars versus Pandas en operaciones fundamentales (filtrado, agregación, joins).
- Construir modelos predictivos robustos utilizando ambas plataformas.
- Cuantificar mejoras de rendimiento (speedup) en diferentes operaciones.
- Analizar la escalabilidad según el tamaño del dataset.
- Comparar estrategias de ejecución (lazy vs eager) en Polars.

3. Metodología

3.1. Dataset y Preparación de Datos

Fuente del Dataset: Kaggle Success Factors

Registros Originales: ~100,000

Registros después de Limpieza: 75,418 (24.6% descartados)

Variables: 40 (numéricas, categóricas, booleanas)

Variable Target: upvotes (numérica, regresión)

Tratamiento de Valores Faltantes:

Se utilizó un enfoque diferenciado según el tipo de dato:

- **Columnas Numéricas:** Imputación con media aritmética
- **Columnas Booleanas:** Imputación con False
- **Columnas Categóricas:** Imputación con 'unknown'
- **Registros con Target Faltante:** Eliminación

División de Datos:

Conjunto de Entrenamiento: 60,334 registros (80%)

Conjunto de Prueba: 15,084 registros (20%)

Estratificación: Por quintiles del target

Random State: 42 (para reproducibilidad)

3.2. Modelos de Machine Learning

Se entrenaron tres modelos de regresión supervisada:

1. Regresión Lineal: Modelo baseline con preprocesamiento (StandardScaler para variables numéricas, OneHotEncoder para categóricas).

2. Random Forest: Conjunto de 50 árboles con max_depth=12, min_samples_split=10, min_samples_leaf=5. Este modelo no requiere escalado de variables.

3. Gradient Boosting: Ensemble de 50 estimadores secuenciales con max_depth=4 y

learning_rate=0.1.

Validación: K-Fold cross-validation con $k=3$ en el conjunto de entrenamiento sin data leakage.

4. Resultados

4.1. Benchmark de Operaciones Individuales

Se midieron cuatro operaciones críticas en pipelines de datos, registrando tiempos de ejecución en ambas plataformas:

Operación	Pandas (s)	Polars (s)	Speedup
Filtrado	0.01167	0.01095	1.07x
GroupBy	0.41736	0.03783	11.03x
JOIN	0.01562	0.00855	1.83x
Pipeline Total	1.39566	0.19984	6.98x

Polars supera a Pandas en todas las operaciones medidas. La operación GroupBy muestra la mayor ventaja relativa (11.03x), mientras que las operaciones simples como filtrado muestran mejoras menores (1.07x). En el pipeline completo, que combina múltiples operaciones, el speedup alcanza 6.98x.

4.2. Rendimiento de Modelos de Predicción

Los tres modelos fueron entrenados con la misma arquitectura de preprocesamiento y validación. Se reportan las métricas estándar para regresión:

Modelo	R ² Test	MAE	RMSE	R ² CV
Regresión Lineal	0.8612	4.1823	48.2904	0.8521
Random Forest	0.8894	3.5460	42.8448	0.9028
Gradient Boosting	0.8781	3.7145	45.1234	0.8872

Random Forest produce el mejor desempeño con R² de 0.8894 en datos de prueba, indicando que el modelo explica 88.94% de la varianza en upvotes. La validación cruzada (R² CV = 0.9028 ± 0.0327) confirma la robustez del modelo. El gap entre training y test es mínimo (<1%), indicando ausencia de overfitting significativo.

5. Análisis y Discusión

5.1. Ventajas de Polars

Rendimiento Superior. Polars demuestra consistentemente mejor rendimiento que Pandas, con speedup de 6.98x en pipelines complejos y 11.03x en operaciones de agregación (GroupBy). Esta ventaja se debe a su implementación en Rust y su optimizador de consultas automático.

Lazy Execution. Polars permite diferir la ejecución de operaciones hasta que sean necesarios los resultados, habilitando optimizaciones automáticas del plan de ejecución.

Escalabilidad. El rendimiento relativo mejora con datasets más grandes y pipelines más complejos, alcanzando speedup de 1.77x en datasets de tamaño medio (50-75% del dataset original).

5.2. Limitaciones de Polars

Integración con Scikit-learn. Polars requiere conversión a Pandas para usar modelos de scikit-learn, lo que añade overhead y reduce los beneficios de rendimiento en la fase de modelado.

Ecosistema en Desarrollo. Comparado con Pandas, Polars tiene menor cantidad de librerías integradas y comunidad más pequeña.

Overhead Inicial. En datasets muy pequeños (<10MB), Polars puede ser más lento que Pandas debido a overhead de compilación.

5.3. Características Predictivas

Las variables más correlacionadas con upvotes son comments_count ($r = 0.83$), views ($r = 0.78$) y downloads ($r = 0.65$). Esto sugiere que el engagement (comentarios, visualizaciones) es el factor dominante en la predicción de upvotes, seguido por la utilidad percibida (descargas).

6. Conclusiones

1. **Ventaja de Rendimiento Significativa.** Polars supera a Pandas con speedup de 6.98x en operaciones complejas, siendo especialmente eficiente en agregaciones (11.03x).
2. **Modelo Predictivo Robusto.** Random Forest logra R^2 de 0.8894 en datos de prueba con validación cruzada de 0.9028 ± 0.0327 , demostrando predicción confiable sin overfitting.
3. **Escalabilidad Mejorada.** El rendimiento relativo de Polars mejora con la complejidad del pipeline, sugiriendo su adopción para ETL grandes (>100MB).
4. **Enganche como Factor Predictivo.** Las métricas de engagement (comments, views) son altamente predictivas de upvotes ($r > 0.78$).

Se recomienda adopción gradual de Polars para pipelines ETL nuevos, manteniendo Pandas para máxima compatibilidad y análisis exploratorio. El uso complementario de ambas herramientas optimiza rendimiento sin sacrificar flexibilidad.

7. Referencias

American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). Washington, DC: Author.

Polars Development Team. (2023). Polars: Lightning-fast DataFrame library for Rust and Python. Retrieved from <https://docs.pola-rs.io/>

The Pandas Development Team. (2023). Pandas: Powerful data structures for data analysis, time series, and statistics. Retrieved from <https://pandas.pydata.org/docs/>

Scikit-learn Developers. (2023). scikit-learn: Machine learning in Python. Retrieved from <https://scikit-learn.org/stable/>